



DEPARTAMENTO
DE INFORMÁTICA
PUC-RIO

INF2072: Tópicos em Inteligência Artificial III - Aprendizado por Reforço Multiagente

Otimização de Logística Autônoma com Aprendizado por Reforço Multiagente

Superando Incertezas Dinâmicas e Desvios Estruturais em
Ambientes Complexos

Alexandre Soares
Eric Goulart
Luca Lima
Yang Ricardo

15 de Junho, 2026

O Desafio Operacional

Navegação Autônoma em Ambientes de Alta Incerteza

Este é um ambiente de armazém 12×8 onde dois robôs (R1 e R2) devem transportar 8 caixas laranjas ('A') para 8 destinos verdes ('B').

O ambiente apresenta dois tipos de obstáculos: paredes fixas ('X') que sempre bloqueiam, e barreiras dinâmicas ('Y') que têm 50% de chance de desaparecer a cada episódio. Os robôs também enfrentam 20% de chance de falha em seus movimentos.

O objetivo é maximizar a recompensa total, completando todas as entregas de forma eficiente e coordenada, usando o algoritmo IDQN e MAPPO.

LEGENDA			
R1 Início do Robô 1	R2 Início do Robô 2	A Caixas (origem)	B Destinos (entrega)
X Obstáculos (bloqueado)	Y Barreira temporária	O Espaço livre	

Linha	R1							R2
11								
10								
9								
8								
7								
6								
5								
4								
3								
2								
1								
0								
Coluna								

Navegação Autônoma em A

Linha 11	R1	0	0	0	0	0	0	R2
10	0	Y	A	A	A	A	0	0
9	0	0	A	A	A	A	0	0
8	X	0	0	0	X	0	Y	0
7	0	Y	X	0	0	0	0	0
6	0	0	0	X	0	Y	X	X
5	0	X	0	Y	0	X	0	0
4	0	0	0	X	0	0	0	0
3	X	0	Y	0	0	0	X	0
2	X	0	B	B	B	B	X	0
1	X	0	B	B	B	B	Y	0
0	0	0	0	Y	0	0	0	0
Coluna	0	1	2	3	4	5	6	7

Ação	Descrição	Recompensa Base
0	Mover para CIMA	-0.005
1	Mover para BAIXO	-0.005
2	Mover para ESQUERDA	-0.005


Característica	Descrição
Dimensões	12 linhas x 8 colunas

El	Total d	Falhas nos Movimentos (20%):
Caix	Células	Quando um robô tenta se mover, há 20% de chance de falha. Em caso de falha: penalidade adicional de -0.15
Destinos 'B'		Pode tentar direção alternativa
Robôs		

Barreiras 'X'	~15	Distribuídas pelo mapa
Barreiras 'Y'	~9	Distribuídas pelo mapa

Modelos Utilizados

Modelos Utilizados




Modelo	Característica Principal	Vantagens	Limitações
Randômico	A principal característica do modelo randômico é a ausência de aprendizado .	- Implementação extremamente simples; - Baixo custo computacional; - Não requer treinamento; - Excelente referência para comparação experimental.	- Não aprende com a experiência; - Não otimiza recompensas; - Desempenho geralmente baixo em tarefas complexas - Não apresenta comportamento cooperativo ou estratégico.
IDQN	Aprendizado independente dos agentes. Cada agente: possui sua própria rede neural; possui sua própria memória de replay; atualiza seus pesos individualmente; não utiliza um mixer ou coordenador central.	É um dos algoritmos multiagentes mais simples de implementar.	Ambiente não estacionário Cada robô altera continuamente o ambiente para os demais agentes.
MPPO	Aprender diretamente uma política probabilística de ações.	Estabilidade O PPO é um dos algoritmos mais estáveis atualmente.	Maior custo computacional Necessita: Actor; Critic; cálculo de vantagens; múltiplas épocas por atualização. Mais memória Treina sobre trajetórias completas.
VDN	A principal característica do VDN é: Decomposição aditiva do valor global.	Melhor coordenação Em tarefas cooperativas como: Mover caixas Logística Transporte Warehouses	Restrição da soma; Nem sempre essa relação é verdadeira. Muitas tarefas possuem interações complexas entre agentes.

Modelos Utilizados


Característica	Random	IDQN	VDN	MPPO
Aprende	Não	Sim	Sim	Sim
Cooperação	Não	Baixa	Média	Muito Alta
Replay Buffer	Não	Sim	Sim	Não
Target Network	Não	Sim	Sim	Não
Política Probabilística	Não	Não	Não	Sim
Mixer Neural	Não	Não	Não	Não
Complexidade	Muito Baixa	Baixa	Média	Muito Alta

Resultados Alcançados


Comparação da Taxa de Sucesso por Episódio (3000 episódios)




Comparação de Colisões por Episódio (3000 episódios)




Comparação de Entregas por Episódio (3000 episódios)



Entregas por Episódio e Média Móvel (100)



Comparação de Falhas por Episódio - R1 e R2 (3000 episódios)



IDQN - R1 Random - R1 VDN - R1 MAPPO - R1
IDQN - R2 Random - R2 VDN - R2 MAPPO - R2